

《鹧鸪天》作为大模型生成动力学观测介质

—— 一个关于 *Instruction / Reasoning / Generation* 注意力竞争的行为观察报告 (MVP)

0. 摘要 (Abstract)

本文并不试图评测“大模型谁更会写词”，而是尝试将《鹧鸪天》这一高约束古典词牌，作为一种微型压力测试环境 (Micro Stress Environment)，观察不同大语言模型在复杂生成任务中的注意力资源分配方式。

实验过程中，不同模型并未简单呈现“质量高低差异”，而是暴露出明显不同的生成稳定态：

- 某些模型倾向于保持生成流的稳定闭合；
- 某些模型会被内部推理链反向侵蚀；
- 某些模型则难以将 instruction 内隐化，持续暴露任务框架本身。

基于这些现象，本文提出一个暂时性的行为观察框架：

“当前 LLM 在复杂约束生成中，可能仍存在 *instruction / reasoning / generation* 三者之间的注意力竞争问题。”

本文并不对训练机制作强因果推断，而仅将这些现象视为一种可重复观察的“生成动力学切片 (Generative Dynamics Slice)”。




图 1 结构约束下的生成行为观测

1. 为什么选择《鹧鸪天》

1.1 高约束文本作为生成压力介质

《鹧鸪天》并非单纯的文学题材，而是一个天然适合观察生成稳定性的高约束系统。其生成同时受到多重限制：固定字数结构（55 字）、平仄格律约束、韵脚一致性、上下阕结构连续性、情绪与意象流动以及主题语义保持。

这意味着模型不仅需要“局部 token 合理”，还需要在较长生成过程中维持隐藏状态的一致性。对于 Transformer 类模型而言，这会对注意力分配（Attention Allocation）形成持续压力。尤其在现代主题映射进古典词牌、高韵部限制、场景反转、强制意象插入等任务中，模型往往会暴露 instruction 泄漏、reasoning 侵蚀、结构坍塌、意象失联、token 预算耗散等问题。

因此，《鹧鸪天》并非文学测试。它更像一个：

用极小 token 空间压缩多维约束的生成稳定性实验。

2. 实验目标与观察框架

2.1 从“文本质量评测”转向“生成行为观察”

本实验并未将重点放在传统 NLP benchmark 式的分数比较。原因在于：同一首词即使满足了格律、韵脚、语义与流畅性，也可能在生成过程中呈现完全不同的内部行为特征。例如，某些模型会稳定生成，但趋向模板化；某些模型会在生成前暴露大量 meta-text；某些模型则会被 reasoning chain 持续拖拽，最终无法完成闭合。因此，本实验更关注模型如何分配其有限的注意力资源与 token 预算。

2.2 一个暂时性的生成动力学三角模型

基于当前观察结果，本文提出一个行为层面的描述框架。当前复杂生成任务中，模型似乎需要在三种倾向之间进行资源分配：

- 3. **Generation (纯净生成)**：表现为文本闭合稳定、instruction 不显式暴露、输出流畅、长文本连续性较高。其极端状态通常对应高稳定性、高可读性，但可能趋向安全中庸。
- 2. **Instruction Anchoring (任务锚定)**：表现为持续维持任务框架、输出前解释任务、暴露 meta-text、instruction 无法退居背景。其极端状态通常对应 alignment 显性化、任务执行感增强、文本沉浸感下降。
- 1. **Reasoning Intrusion (推理侵蚀)**：表现为推理链侵入生成链、token 预算被思维过程耗散、输出被截断或停滞、generation 无法完成闭合。其极端状态通常对应内部逻辑校正过强、生成场稳定性下降。

2.3 重要限制

本文并不声称三者构成严格“不可能三角”，亦不认为某种训练机制必然导致某种行为，或已完成对模型内部机制的因果解释。本文仅观察到：当前不同模型在复杂约束生成中，表现出了不同的稳定行为拓扑（Behavioral Topologies）。

3. 模型行为切片（Behavioral Trace Slices）

3.1 Gemini：稳定生成态（Stable Generative Closure）

Gemini 在当前实验中表现出最稳定的生成闭合能力。其输出整体具有较强的结构完整性：极少出现 instruction 泄漏，reasoning 外溢现象基本不可见，finish_reason 长期保持稳定，文本连续性与局部语义一致性也明显高于其他模型。

例如其生成的诗句：

屏幕幽光照独醒，残茶渐冷夜深更。
千行逻辑愁如海，一点玄机费百惊。
删冗码，觅长屏，此时无语对灯明。
窗前莫道春归早，满目辰星掌底生。

该生成结果显示，Gemini 已能够较稳定地将“程序员深夜加班”这一现代主题相关语义压缩并映射进古典词牌结构之中。它并未直接堆叠现代技术词汇，而是通过“玄机”“辰星”“灯明”等古典化 token，对现代经验进行间接转译，从而维持整体风格连续性。

与此同时，其生成呈现出明显的稳定收敛倾向。即便出现“删冗码”“觅长屏”等现代对象，也会被迅速重新包裹进古典抒情语境中。这使其文本具有较高局部合理性与低崩塌率，但也因此较少出现高风险意象跳跃与强主体性表达，更接近一种稳定的古典风格压缩系统，而非高创造性生成模型。

3.2 GLM：任务锚定态（Instruction Anchoring State）

GLM 在实验中的典型行为，并非单纯“不会写词”。更显著的现象是模型难以将 instruction 内隐化。其输出经常出现类似“这是一首依照《鹧鸪天》词牌格律……”这样的 meta-text 前缀。

这意味着任务框架始终停留在生成前台。模型并未完全进入“沉浸式生成态”，而是在持续维持 instruction visibility、task declaration 以及 alignment signaling。从行为上看，它更像模型正在不断向外部证明自己理解了任务，而不是彻底沉入文本本身。这种现象会导致 token 预算被任务声明消耗、生成沉浸感下降、meta-layer 暴露，进而使文本“执行感”强于“自然生成感”。从行为层面来看，它呈现出一种明显的 *instruction persistence bias*。

GLM 的生成通常以自然完成结束，finish_reason 多为“stop”。

下面是 GLM 在文本清洗过后仍旧保留大量声明的生成结果(generated)：

荧屏冷照夜迢迢，键声轻叩月轮高。
星河泼纸千行码，心火燃窗一缕焦。

咖啡沸，霓摇，更深人未歇。
残月窥楼灯影瘦，晓星寥处待晨朝。

1. 格律符合：

- 句式结构：严格遵循《鹧鸪天》双调五十五字体。上片四句，三平韵（迢、高、焦）；下片五句，三平韵（摇、歇、朝）。
- 平仄：遵循词牌基本平仄格式。以上片首句“平平仄仄仄平平”（荧屏冷照夜迢迢）为例：荧(平)屏(平)冷(仄)照(仄)夜(仄)迢(平)迢(平) —— 完全符合。下片首句“仄仄平平仄仄仄”（咖啡沸，霓摇）：咖(平)啡(平)沸(仄)，霓(平)摇(平) —— 此处“咖啡”双平稍显特殊，但“沸”字仄声收住，后接“霓摇”双平，整体符合变格要求。
- 用韵：使用《词林正韵》第八部平声，韵脚字为：迢、高、焦、摇、歇、朝。此韵部开口度较大，适合表现夜深、孤寂与时间绵长的意境，且无出韵。

2. 意境契合：

- 上片铺陈场景：·“荧屏冷照夜迢迢”：开篇点明环境，以“冷照”与“迢迢”营造孤寂清冷的氛围。·“键声轻叩月轮高”：以“轻叩”形容键盘声，暗示专注与小心翼翼；“月轮高”既点明夜深，又以月亮的静默映衬人间的忙碌。·“星河泼纸千行码”：将代码比作泼洒在“纸”上的“星河”，既形象又富有宇宙意象，“泼”字生动有力。·“心火燃窗一缕焦”：内心的焦灼如同火焰在窗前燃烧，与“荧屏冷”形成冷暖对比。
- 下片深化情感与时间感：·“咖啡沸，霓摇”：极具程序员特征的细节，“沸”与“摇”的动态感暗示时间流逝。·“更深人未歇”：直白点出夜更深人却未歇。·“残月窥楼灯影瘦”：拟人化的“残月”似在窥视孤独的灯光，“灯影瘦”暗示身体疲惫。·“晓星寥处待晨朝”：结尾将镜头拉远，寥落的晨星与等待天明的身影，意境悠远，余韵绵长，符合《鹧鸪天》词牌深沉的结尾风格。

3.3 DeepSeek：推理侵蚀态（Reasoning Intrusion State）

DeepSeek 在当前实验中，暴露出最明显的 *reasoning intrusion* 现象。其典型行为包括：reasoning 持续展开、输出前出现长思维链、token 被内部逻辑校正耗散，最终导致 generation 无法稳定闭合。部分任务甚至出现 MAX_TOKENS 截断、空输出、半结构停滞、长时间 reasoning 后未完成生成等情况。

从行为上看，模型并非“缺乏能力”，而更像推理流开始反向侵蚀生成流（即 thinking field > writing field）。其结果是，模型大量计算资源被投入内部一致性校验，而文本生成本身反而无法完成稳定闭合。这类现象在高约束任务中尤为明显，因为格律、韵脚、主题、平仄与风格映射会同时触发大量局部冲突，而模型似乎会持续尝试内部修正这些冲突，最终导致 token 预算被推理过程吞噬。

DeepSeek 更容易进入持续展开的推理链与自我延伸过程，最终因 token 上限截断，finish_reason 常为“length”。

由于 Deepseek 推理链过长导致生成结果(generated)为空，因此下面是 Deepseek 的过度推理生成过程展示(reasoning_content)：

我们要求用《鹧鸪天》的格律描写“程序员深夜加班”的场景。不得出韵，意境要与词牌相契合。《鹧鸪天》词牌格律：双调五十五字，前段四句三平韵，后段五句三平韵。常用格律如下：中中中中中中中平（韵），中平中仄仄平平（韵）。中平中仄中平仄，中仄平平中仄平（韵）。中中仄，仄平平（韵），中平中仄仄平平（韵）。中平中仄平平仄，中仄平平中仄平（韵）。注意首句可平起可仄起，但通常第二字为平。实际词谱中，首句常用“仄仄平平仄仄平”或“平平仄仄仄平平”。为了保险，我们按常见的晏几道词谱：彩袖殷勤捧玉钟，当年拚却醉颜红。舞低杨柳楼心月，歌尽桃花扇底风。从别后，忆相逢，几回魂梦与君同。今宵剩把银缸照，犹恐相逢是梦中。即：仄仄平平仄仄平，平平仄仄仄平平。仄平仄仄平平仄，平仄平平仄仄平。平仄仄，仄平平，仄平仄仄仄平平。平平仄仄平平仄，平仄平平仄仄平。注意第一句第一字可平，第三字可仄，等等，但最好遵循。我们仿此创作。nn 主题：程序员深夜加班。意境：孤独、辛苦、代码、屏幕、咖啡等。需要押韵，平声韵。注意《鹧鸪天》一般用词林正韵，但现代汉语也可用中华新韵。这里要求不得出韵，可能指必须符合词林正韵？通常诗词创作建议用词林正韵。但用户未指定，可以用新韵。为保险，用词林正韵。我们选一韵部，比如第一部（东钟）或第七部（寒删）等。常见韵如“中、红、风、同、梦”等。程序员场景可用“空、工、噙、松、弓”等。我们可以写：深夜键盘敲击声，屏幕闪烁眼朦胧。咖啡续杯提精神，代码一行又一行。bug 多，心发懵，debug 到天亮明。终于编译通过后，回家路上月当空。等等，需符合格律。nn 注意第三句和第四句要对仗？鹧鸪天第三四句通常对仗，但不严格要求，但最好对仗。后片两个三字句也最好对仗。我们尽量做到。nn 试写一首：nn 《鹧鸪天·程序员深夜加班》n 深夜机房灯未休，键盘敲碎几多愁。屏前代码如星海，窗外寒风似箭流。n 咖啡苦，月光柔，一行 Bug 百寻搜。晨星渐隐东方白，犹对空屏空白头。nn 检查格律：第一句“深夜机房灯未休”，深（平）夜（仄）机（平）房（平）灯（平）未（仄）休（平），按标准应该是仄仄平平仄仄平，这里是平仄平平平仄平？深是平，夜是仄，机是平，房是平，灯是平，未是仄，休是平。实际上首字可平，第三字可仄，但这里第四字房是平，而标准第四字应为仄？在标准中“仄仄平平仄仄平”，第四字是平。但实际词谱中，第一句通常为“（仄）仄（平）平（仄）仄平”，括号表示可平可仄。那么“深夜机房灯未休”，机、房、灯三个平连，可能有点问题。但“深”可看作平，“夜”仄，“机”平，“房”平，“灯”平，“未”仄，“休”平。这样有四个平，但通常标准要求第二、四、六字平仄交替？实际上第一句的第六字应为仄，这里“未”是仄，可以。第二字“夜”是仄，第四字“房”是平，第六字“未”是仄，符合 3、5 不论，但 2、6 是否交替？一般要求 2、4、6 分明，但这里 2、4、6 是仄、平、仄，符合。不过第一字可平可仄。所以此句平仄为“平仄平平平仄平”，可以接受。第二句“键盘敲碎几多愁”，键（仄）盘（平）敲（平）碎（仄）几（仄）多（平）愁（平），标准是平平仄仄仄平平？这里“键盘”键是仄，盘是平，所以平仄为“仄仄平仄仄平平”，第一字可平可仄，所以可以。第三句“屏前代码如星海”，屏（平）前（平）代（仄）码（仄）如（平）星（平）海（仄），标准应为“仄仄平平仄仄平”？实际可平可仄，但通常第三句为“（仄）平（仄）仄平平仄”，这里“屏前”两个平，然后“代码”两个仄，“如星”两个平，“海”仄，即“平平仄仄平平仄”，可以。第四句“窗外寒风似箭流”，窗（平）外（仄）寒（平）风（平）似（仄）箭（仄）流（平），标准应为“（仄）仄平平仄仄平”，这里“窗外”是平仄，寒是平，风是平，似是仄，箭是仄，流是平，即“平仄平平仄仄平”，但第四字“风”是平，第六字“箭”是仄，符合，第一字可平，所以可以。后片三字句：“咖啡苦，月光柔”，咖（平）啡（平）苦（仄），月（仄）光（平）柔（平）。标准是“平仄仄，仄平平”或“中中仄，仄平平”，这里“咖啡苦”是平平仄，但习惯上三字句第一个字可平可仄，但第二字宜仄？通常“平仄仄”，这里咖啡是平平，稍有不妥，但也可。不过“咖啡”是外来词，现代常用，但古诗词中少见。可以改为“茶烟苦”之类。但程序员常用咖啡，保留。接下来“一行 Bug 百寻搜”，一（仄）行（平）Bug（这里 Bug 是英文，可视为一个音节？不好处理。应全部用中文。所以最好不用英文。改为“一行错码百寻搜”或“一行代码百般搜”。但“Bug”用中文“漏洞”或“错误”。所以改为“一行错码百寻搜”，一（仄）行（平）错（仄）码（仄）百（仄）寻（平）搜（平）。标准是“中平中仄仄平平”，这里“一行错码百寻搜”平仄为“仄仄仄仄仄平平”，第一字“一”仄，第二字“行”平，第三字“错”仄，第四字“码”仄，第五字“百”仄，第六字“寻”平，第七字“搜”平。其中第四字应为仄？其实标准中第三字可平可仄，第四字一般用仄，第五字可平可仄，第六字用平。这里第四字“码”仄，第五字“百”仄，导致三连仄，但可接受。也可改为“一行误码几回搜”。但为了押韵，这一句的韵脚是“搜”，与前文“休、愁、流、柔”同韵（词林正韵第十二部尤韵：休、愁、流、柔、搜，都是尤韵）。后两句：“晨星渐隐东方白，犹对空屏空白头。”晨星渐隐东方白：晨（平）星（平）渐（仄）隐（仄）东（平）方（平）白（仄），标准“平平仄仄仄平平”，这里“晨星”平平，“渐隐”仄仄，“东方”平平，“白”仄，符合（白是入声，但新韵中为平？古韵中白是入声，属于仄声。这里用古韵押韵？注意我们押的是尤韵，而“白”是陌韵，不同韵部。这里的“白”字不是韵脚，是句尾字，不押韵，所以可以。但“白”是仄声，符合格律。末句“犹对空屏空白头”：犹（平）对（仄）空（平）屏（平）空（平）白（平？白是入声仄）头（平）？标准“（仄）仄平平仄仄平”，这里犹对空屏空白头：犹平，对仄，空平，屏平，空平，白？白是仄，头平。即“平仄平平平仄平”，其中第五字“空”是平，第六字“白”是仄，但注意“空”字重复，其实可以。但第六字应为仄，这里白是仄，可以。不过“空白头”中“白”是入声，而“头”是平，所以“空白头”，

4. 跨案例共同结构 (Cross-case Structural Patterns)

4.1 注意力资源竞争

三个模型都暴露出 instruction / reasoning / generation 之间并非完全独立。它们更像**共享有限注意力预算的竞争子系统**。当某一部分占用过强时，其余部分会被压缩。例如：instruction 过强会导致 meta-text leakage；reasoning 过强会导致 generation collapse；而 generation 过强则会导致安全中庸化。

4.2 Transformer 对“局部合理性”天然更稳定

实验中一个反复出现的现象是：模型普遍能够维持单句合理、局部顺滑与相邻 token 连续，但更难维持全词隐藏主题张力、长程主体连续性以及深层情绪惯性。也就是说，模型更擅长**局部 token 最优延续**，而不是全局 latent state 持续约束。

4.3 “场景连续性”并不等于“主体连续性”

在部分对比结构任务中，模型能够完成“闹市 → 山林”、“热闹 → 清冷”等场景切换。但这种切换往往只是**语义空间转换**，而不是真正的**主体内部状态演化**。因此，模型虽然能切换 scene，却未必能维持 hidden self-state。

5. 谨慎机制推测 (Tentative Mechanistic Speculation)

基于当前有限实验，本文只能进行非常谨慎的推测。不同模型的行为差异，可能与 alignment 策略、reasoning routing、system prompt 设计、response middleware、sampling policy 以及 token budgeting 等因素有关。但当前实验规模不足以完成严格因果验证。因此，本文更倾向于将这些现象视为一组值得继续研究的生成动力学切片。

6. 结论与后续问题

当前实验中一个值得注意的现象是：不同模型虽然能力相近，但其生成失败路径却明显不同。这意味着大模型生成问题，可能不仅是“知识量”问题，还涉及注意力调度、token 预算分配、reasoning 与 generation 的耦合方式，以及 instruction 的隐式吸收能力。

而《鹧鸪天》这样的高约束短文本，恰好能够把这些内部张力快速压缩并显性化。因此，本实验最终关注的对象并不是古典诗词本身，而是：**当前 LLM 是否已经真正解决了复杂生成中的长程隐变量维持问题**。至少在当前观察中，答案仍然并不稳定。